



Kanton Zürich
Direktion der Justiz und des Innern
Statistisches Amt

Von losen Zeilen Code zum ersten Package

Erfahrungsbericht eines Code-Refactorings


3. April 2025 | Christoph Zust | Team Data


Ausgangslage

- Was ist das bestehende Produkt?
 - Deskriptive Aufbereitung von Individualdaten und Integrationsangebote für Asylsuchende im Kt. Zürich
- Was muss das Produkt lösen?
 - Überblick über die Nutzung von Integrationsangeboten
- Replizier- und Nachvollziehbarkeit wichtig


Reports zeigen

Oder in anderen Worten






Data	
ang_alle	15396 obs. of 2 variables
ang_alle_ak	15396 obs. of 4 variables
ang_alter_ak	15396 obs. of 4 variables
ang_auf	15396 obs. of 3 variables
ang_auf_ak	15396 obs. of 4 variables
ang_auf_ak_alter1	4822 obs. of 5 variables
ang_auf_ak_alter2	10227 obs. of 5 variables
ang_auf_ak_dauer	15396 obs. of 4 variables
ang_auf_ak_herkun...	15396 obs. of 4 variables
ang_auf_dauer	15396 obs. of 2 variables
ang_auf_herkunft	15396 obs. of 2 variables
ang_gesch	15396 obs. of 3 variables
ang_gesch_ak	15396 obs. of 5 variables
ang_gesch_ak_alte...	4822 obs. of 4 variables
ang_gesch_ak_alte...	10227 obs. of 4 variables
check_me	0 obs. of 2 variables
con	List of 6
control_gde_after...	147 obs. of 2 variables
control_gde_fi	147 obs. of 2 variables
control_gde_ktzh	160 obs. of 2 variables
df	15396 obs. of 46 variables
df_alle_daten	15394 obs. of 46 variables
df_merged_gde	15396 obs. of 40 variables
df2	1141 obs. of 4 variables
df2_alle	160 obs. of 2 variables
df2_auf	743 obs. of 3 variables
df2_gesch	318 obs. of 3 variables
df2_mit_unbekannt...	1434 obs. of 4 variables
df3_alle	5447 obs. of 2 variables
df3_alle_ak	7078 obs. of 3 variables
df3_alter_ak	7078 obs. of 4 variables
df3_auf	5538 obs. of 3 variables
df3_auf_ak	7158 obs. of 4 variables
df3_auf_ak_alter1	2532 obs. of 5 variables
df3_auf_ak_alter2	4468 obs. of 5 variables
df3_auf_ak_dauer	7088 obs. of 4 variables
df3_auf_ak_herkun...	7079 obs. of 4 variables
df3_auf_dauer	4914 obs. of 1 variable
df3_auf_herkunft	4905 obs. of 1 variable
df3_gesch_ak	7078 obs. of 4 variables
df3_gesch_ak_alte...	2509 obs. of 5 variables
df3_gesch_ak_alte...	4411 obs. of 5 variables




Immer noch
unübersichtlich,
schwierig zu warten und
weiterzuentwickeln ...

... und wahrscheinlich
ähnlich wie, wenn ich
es selbst aufgebaut
hätte (🙄) ...



... bis ich im Team Data
angefangen habe.

Die Lösung: Erstelle ein Package




[R Packages \(2e\)](#)

Package Development : : CHEATSHEET

Package Structure

A package is a convention for organizing files into directories. This cheat sheet shows how to work with the 7 most common parts of an R package:



There are multiple packages useful to package development, including `usethis` which handily automates many of the more repetitive tasks. Install and load `devtools`, which wraps together several of these packages to access everything in one step.

Getting Started

Once per machine:

- Get set up with `usethis` so `devtools` is always loaded in interactive R sessions

```
if (interactive()) {
  require("devtools", quietly = TRUE)
  # automatically attaches usethis
}
```


- `create_github_token()` — Set up GitHub credentials
- `git_vaccinate()` — Ignores common special files

Once per package:

- `create_package()` — Create a project with package scaffolding
- `use_git()` — Activate git
- `use_github()` — Connect to GitHub
- `use_github_action()` — Set up automated package checks

Having problems with git? Get a situation report with `git_sitrep()`.

Workflow



- `load_all()` (Ctrl/Cmd + Shift + L) — Load code
- `document()` (Ctrl/Cmd + Shift + D) — Rebuild docs and NAMESPACE
- `test()` (Ctrl/Cmd + Shift + T) — Run tests
- `check()` (Ctrl/Cmd + Shift + E) — Check complete package

folder R/

All of the R code in your package goes in folder `R/`. A package with just an `R/` directory is still a very useful package.

- Create a new package project with `create_package("path/to/name")`.
- Create R files with `use_r("file-name")`.

- Follow the tidyverse style guide at style.tidyverse.org
- Click on a function and press F2 to go to its definition
- Find a function or file with `Ctrl + .`



? DESCRIPTION

The `DESCRIPTION` file describes your work, sets up how your package will work with other packages, and applies a license.

- Pick a license with `use_mit_license()`, `use_gpl3_license()`, `use_proprietary_license()`.
- Add packages that you need with `use_package()`.

Import packages that your package requires to work. R will install them when it installs your package.

`use_package(x, type = "imports")`

Suggest packages that developers of your package need. Users can install or not, as they like.

`use_package(x, type = "suggests")`

? NAMESPACE

The `NAMESPACE` file helps you make your package self-contained: it won't interfere with other packages, and other packages won't interfere with it.

- Export functions for users by placing `@export` in their roxygen comments.
- Use objects from other packages with `package::object` or `@importFrom package object` (recommended) or `@import package` (use with caution).
- Call `document()` to generate `NAMESPACE` and `load_all()` to reload.

DESCRIPTION	NAMESPACE
Makes packages available	Makes function available
Mandatory	Optional (can use <code>::</code> instead)
<code>use_package()</code>	<code>use_import_from()</code>



Nun fragt ihr euch vielleicht:



Vorteile eines Packages



Zwingt einen das Projekt strukturiert(er) anzugehen




Alle notwendigen Inputs können ganz einfach am Anfang definiert und angepasst werden




Code-Struktur wird überschaubarer



Code ist einfacher zu warten und zu erweitern



RUNME.R





```
df_1 <- df |>  
  mutate(herkunft) |>  
  mutate(alter)
```



```
transform_data <- function(df) {  
  df_1 <- df |>  
    sub_function_1() |>  
    sub_function_2()  
  return(df_1)  
}
```



```
df_1 <- df |>  
  transform_data()
```



```
df_2 <- df |>  
  group_by() |>  
  summarise()
```



```
analyze_data <- function(df) {  
  df2 <- df |>  
    group_by() |>  
    summarize  
  return(df_2)  
}
```



```
df_2 <- df_1 |>  
  analyze_data()
```




Beispiel: prepare_data_iazh()


- Inhalt
- Dokumentation
- Checks


```
22 #' Prepare individual-level data
23 #'
24 #'
25 #' Prepare clean individual-level data for the respective report type including
26 #' the required variables for the analysis.
27 #'
28 #' @inheritParams create_full_report_data
29 #' @inheritParams get_gemeinden_without_ksa
30 #' @param df_gemeinden A data frame of all current municipalities in the Canton
31 #' of Zürich.
32 #'
33 #' @return A data frame with the processed individual-level data.
34 prepare_data_iazh <- function(df_iazh, df_gemeinden, ksa_gemeinden, ksa_name,
35                               countries, report_type, report_year) {
36   if (report_type == "without_S") {
37     df_iazh <- df_iazh |> dplyr::filter(aufenthaltsstatus_code != 5)
38   } else {
39     if (report_type == "S_only") {
40       df_iazh <- df_iazh |> dplyr::filter(aufenthaltsstatus_code == 5)
41     } else {
42       stop(paste0("'", report_type, "' is not a valid report type.
43                 Valid report types are 'without_S' and 'S_only'."))
44     }
45   }
46
47   check_eintrittsdatum_for_NA(df_iazh)
48
49   df_iazh <- df_iazh |>
50     dplyr::left_join(df_gemeinden, by = c("gde_bfsnr"))
51
52   # Check if there are any irregularities in the gemeente codes of the IAZH data
53   check_for_gemeinde_match(df_iazh, df_gemeinden, ksa_gemeinden)
54
55   df_iazh <- df_iazh |>
56     create_kosten_categories_iazh() |>
57     create_alter_categories_iazh() |>
58     create_angebot_categories_iazh() |>
59     create_herkunft_iazh(countries) |>
60     create_aufenthaltsdauer_iazh(report_year, report_type) |>
61     create_ksa_gemeinde(ksa_gemeinden = ksa_gemeinden, ksa_name = ksa_name) |>
62     adjust_gemeinde_names()
63
64   return(df_iazh)
65 }
66
```

Die Lösung: Erstelle ein Package



[R Packages \(2e\)](#)







4.1 Angebotsbesuche im Kanton ZH pro Angebotsart und Geschlecht

Excel

CSV

Copy

Search:

Angebotsnummer	Geschlecht	Personen	Anteil Personen nach GG	Besuche	Anteil Besuche nach GG
A-01	männlich	33	43%	34	40%
A-01	weiblich	44	57%	52	60%
A-02	männlich	21	54%	24	48%
A-02	weiblich	18	46%	26	52%
AI-01	männlich	133	55%	239	44%
AI-01	weiblich	111	45%	304	56%
AI-02	männlich	142	49%	263	46%
AI-02	weiblich	145	51%	315	54%
AI-03	männlich	13	30%	14	29%
AI-03	weiblich	30	70%	34	71%

Showing 1 to 10 of 24 entries

Previous

1

2

3

Next

Zusätzliche Erläuterungen: Anzahl der im Fördersystem für Geflüchtete geförderten Geflüchteten sowie Anzahl genutzter Angebote aus dem kantonalen Angebotskatalog IAZH aufgeschlüsselt nach Angebotsart und Geschlecht im Kanton ZH.

Data	
ang_alle	15396 obs. of 2 variables
ang_alle_ak	15396 obs. of 4 variables
ang_alter_ak	15396 obs. of 4 variables
ang_auf	15396 obs. of 3 variables
ang_auf_ak	15396 obs. of 4 variables
ang_auf_ak_alter1	4822 obs. of 5 variables
ang_auf_ak_alter2	10227 obs. of 5 variables
ang_auf_ak_dauer	15396 obs. of 4 variables
ang_auf_ak_herkun...	15396 obs. of 4 variables
ang_auf_dauer	15396 obs. of 2 variables
ang_auf_herkunft	15396 obs. of 2 variables
ang_gesch	15396 obs. of 3 variables
ang_gesch_ak	15396 obs. of 5 variables
ang_gesch_ak_alte...	4822 obs. of 4 variables
ang_gesch_ak_alte...	10227 obs. of 4 variables
check_me	0 obs. of 2 variables
con	List of 6
control_gde_after...	147 obs. of 2 variables
control_gde_fi	147 obs. of 2 variables
control_gde_ktzh	160 obs. of 2 variables
df	15396 obs. of 46 variables
df_alle_daten	15394 obs. of 46 variables
df_merged_gde	15396 obs. of 40 variables
df2	1141 obs. of 4 variables
df2_alle	160 obs. of 2 variables
df2_auf	743 obs. of 3 variables
df2_gesch	318 obs. of 3 variables
df2_mit_unbekannt...	1434 obs. of 4 variables
df3_alle	5447 obs. of 2 variables
df3_alle_ak	7078 obs. of 3 variables
df3_alter_ak	7078 obs. of 4 variables
df3_auf	5538 obs. of 3 variables
df3_auf_ak	7158 obs. of 4 variables
df3_auf_ak_alter1	2532 obs. of 5 variables
df3_auf_ak_alter2	4468 obs. of 5 variables
df3_auf_ak_dauer	7088 obs. of 4 variables
df3_auf_ak_herkun...	7079 obs. of 4 variables
df3_auf_dauer	4914 obs. of 1 variable
df3_auf_herkunft	4905 obs. of 1 variable
df3_gesch_ak	7078 obs. of 4 variables
df3_gesch_ak_alte...	2509 obs. of 5 variables
df3_nach_ak_alte...	4411 obs. of 5 variables

Das Environment des Grauens muss weg – aber wie?

- Eigenheit des Produkts: ganz viele summary-tables

```
df_2 <- df |>
  group_by() |>
  summarise()
```

→ Lösungsansatz:

- Wechsel von wide zu long Format
- Wenn du etwas mehr als zwei Mal machen musst, schreibe eine Funktion!

From wide to long

id	aufenthaltsstatus	aufenthaltsdauer	herkunft	geschlecht
12345678	Asylsuchende (N)	4-5 Jahre	Mars	männlich

```
df_long <- df_wide |>
  pivot_longer()
```

id	var_name	var_typ	table_name
12345678	aufenthaltsstatus	Asylsuchende (N)	aufenthaltsstatus_fb
12345678	aufenthaltsdauer	4-5 Jahre	aufenthaltsdauer_fb
12345678	herkunft	Mars	herkunft_fb
12345678	geschlecht	männlich	geschlecht_fb

From long to summary-tables (1/3)

id	var_name	var_typ	table_name
12345678	aufenthaltsstatus	Asylsuchende (N)	aufenthaltsstatus_fb
12345678	aufenthaltsdauer	4-5 Jahre	aufenthaltsdauer_fb
12345678	herkunft	Mars	herkunft_fb
12345678	geschlecht	männlich	geschlecht_fb

```
df_summary <- df_long |>
  group_by(var_name, var_typ, table_name) |>
  summarise(anzahl = n())
```


var_name	var_typ	table_name	anzahl
herkunft	Merkur	herkunft_fb	1252
herkunft	Venus	herkunft_fb	1364
herkunft	Mars	herkunft_fb	1509
herkunft	Jupiter	herkunft_fb	1038

From long to summary-tables (2/3)


var_name	var_typ	table_name	anzahl
herkunft	Merkur	herkunft_fb	1252
herkunft	Venus	herkunft_fb	1364
herkunft	Mars	herkunft_fb	1509
herkunft	Jupiter	herkunft_fb	1038
aufenthaltsdauer	...	aufenthaltsdauer	...
aufenthaltsdauer	...	aufenthaltsdauer	...
geschlecht	...	geschlecht_fb	...
geschlecht	...	geschlecht_fb	...
aufenthaltsstatus	...	aufenthaltsstatus	...
aufenthaltsstatus	...	aufenthaltsstatus	...

```
list_summary_tables <- df_summary |>
  split(table_name)
```


From long to summary-tables (3/3)




In anderen Worten - bisher



In anderen Worten - neu





4.1 Angebotsbesuche im Kanton ZH pro Angebotsart und Geschlecht

[Excel](#)
[CSV](#)
[Copy](#)

Search:

Angebotsnummer	Geschlecht	Personen	Anteil Personen nach GG	Besuche	Anteil Besuche nach GG
A-01	männlich	33	43%	34	40%
A-01	weiblich	44	57%	52	60%
A-02	männlich	21	54%	24	48%
A-02	weiblich	18	46%	26	52%
AI-01	männlich	133	55%	239	44%
AI-01	weiblich	111	45%	304	56%
AI-02	männlich	142	49%	263	46%
AI-02	weiblich	145	51%	315	54%
AI-03	männlich	13	30%	14	29%
AI-03	weiblich	30	70%	34	71%

Showing 1 to 10 of 24 entries

Previous

1


2


3


Next

Zusätzliche Erläuterungen: Anzahl der im Fördersystem für Geflüchtete geförderten Geflüchteten sowie Anzahl genutzter Angebote aus dem kantonalen Angebotskatalog IAZH aufgeschlüsselt nach Angebotsart und Geschlecht im Kanton ZH.

export_report_data()







Fülle die Lücken

Tina pflückt im Garten_____.
 Madrid ist die_____von Spanien.
 Mutter kauft das Brot beim_____.
 Ich_____gerne ein Glas Milch.
 Im_____läuft ein spannender Film.
 Der Arzt_____Medikamente.
 In den_____fahren wir ans Meer.
 Ein Ritter trägt eine_____.
 Die Fahne_____lustig im Wind.

Bäcker verschreibt Kino
 trinke flattert Himbeeren
 Rüstung Hauptstadt Ferien



Section header

Text

Subsection header

Table

Section header

Dynamic text

Subsection header

Table

Quarto zeigen

Was solltet ihr euch merken



Was solltet ihr euch merken

- Von Excel zu R ist gut 
- Von einzelnen Skripts zu Package-based Workflows ist noch besser  
- Der Long-Format-Ansatz verleiht ungeahnte Flexibilität 