

R@USZ: Automatisierte Textkategorisierung zurückgewiesener elektronischer Behandlungsabrechnungen mit Machine Learning Methods

Pascal Hertwig, Senior Data Scientist

Gregori Schmid, Data Scientist

R@USZ

Einführung Machine Learning

Gregori Schmid, Data Scientist

Agenda

1. ML-Grundlagen
2. CRM-Projekt und Textkategorisierungs-Algorithmus
3. Beispiel in R


ML-Grundlagen

Gregori Schmid, Data Scientist



Agenda

1. Weshalb Machine Learning?
2. Was ist Machine Learning?
3. Data Science Cycle
4. Supervised vs. Unsupervised
5. Ausblick


Weshalb Machine Learning?




Was ist Machine Learning?




Machine Learning Model



Beispiel: lineare Regression




Beispiel: lineare Regression




Beispiel: lineare Regression

$$\textit{Wohnungspreis} = \beta_0 + \beta_1 * \textit{Quadratmeter} + C$$


Data Science Cycle



Supervised and Unsupervised Training



Ausblick



R@USZ

CRM-Projekt und Textkategorisierungs-Algorithmus

Pascal Hertwig, Senior Data Scientist

R@USZ

CRM-Projekt und Textkategorisierungs-Algorithmus

Pascal Hertwig, Senior Data Scientist


Agenda

1. Kurzvorstellung Ertragsmanagement
2. CRM-Tool
3. CRM-Projekt
4. Automatisierung via Textkategorisierungs-Algorithmus
5. Scripts
6. Ausblick
7. Fragen

1. Kurzvorstellung Ertragsmanagement

Arbeitsinhalte

- Bereich der Direktion Finanzen
- Patientenaufnahme und Kostensicherung aller eintretender Patienten
- Fakturierung ambulant, stationär und externer Auftrag nach gültigen Tarifen
- Bearbeitung von rechnungsbezogenen Anfragen und Rückweisungen von Kostenträgern und Patienten
- Entwicklung der KISIM-Spektren und Erstellung von KISIM-Kontroltools
- Monitoring und Überwachung der vollständigen Leistungsübermittlung von allen internen und externen Leistungserfassungssystemen zum SAP IS-H
- Daten-, Prozess- und Systemoptimierungen sowie Auswertungen von der Aufnahme bis und mit zur Zahlung (O2C)



2. CRM-Tool



Tool

- SAP CRM (Customer Relationship Management) als zentrales Dokumentations- und Korrespondenz-Tool zur Bearbeitung von rechnungsbezogenen Rückweisungen und Anfragen von Patienten und Kostenträgern
- Verknüpfung zu SAP IS-H (Spitalmodul)
- Geschäftsfälle (GF) als zentrales Messkriterium
- Cirka 200 Mitarbeitende im SAP CRM in diversen Organisationseinheiten
- **Eingänge**
 - **Briefpost** (via Scanning-Center in Schlieren)
 - **E-Mail** (definierte Posteingänge je Fallart)
 - **Elektronische Rückweisungen** (Via Medidata nach schweizweiten Standard gemäss Forum Datenaustausch in XML-Format)

Statistik

- 80'000 GF pro Jahr mit einem gesperrten Rechnungsvolumen von CHF 450'000'000.00.-
 - 28'000 GF via E-Mail
 - 8'000 GF via Briefpost
 - 37'000 GF via elektronische Rückweisungen
- Durchschnittliche Bearbeitungszeit liegt bei 70 Tage je GF durch Mitarbeitende im Fachbereich sowie weiteren Organisationseinheiten
- Im Jahr 2023 stieg die Anzahl der GF um 20%, weshalb ein Automatisierungsprojekt beschlossen wurde (CRM-Projekt)

3. CRM-Projekt

Aufteilung in vier Teilprojekte

- CRM – Technisch
 - Teilautomatisierung Triage
 - Teilautomatisierung Geschäftsfalleröffnung
 - Teilautomatisierung Standardprozesse
- CRM – Organisatorisch
 - Überarbeitung Geschäftsfallkategorien
 - Entwicklung CRM-Monitoring
- Massenproblematiken
 - Identifizierung, technische und organisatorische Behebung
- Arbeitsprozesse und –organisation
 - Aufbau Wissensmanagement

Prozessablauf CRM-Tool



4. Automatisierung via Texterkennungs-Algorithmus

Automatisierungspotential

- Eingehende Rechnungsrückweisungen und –anfragen werden je Fallart, fachlicher OE, Sachverhalt und Zuständigkeit durch ein Team kategorisiert, beschriftet und an die zuständigen Fachabteilungen weiter triagiert. Dieser Prozess bindet cirka 300% Stellenprozente im Fachbereich und lässt sich komplett automatisieren


Datengrundlagen

- Benötigte Daten zur Trainierung eines ML-Modell
 - Fallart
 - Falltyp
 - Fachliche OE
 - Sachverhalt (Textdaten aus XML)

Benötigte Funktionalitäten

- Bereitstellung von Trainingsdaten aus dem SAP CRM via einer zu errichtenden Export-Funktion (csv-Export)
- Ansteuerung der GF via einer Import-Funktion (csv-Upload)

4. Automatisierung via Texterkennungs-Algorithmus




4. Automatisierung via Texterkennungs-Algorithmus

Buchempfehlung

von Emil Hvitfeld und Julia Silge (2022)

- Erklärung zu Sprachverarbeitung wie:
 - Tokenization, Stop Words, Stemming, Word Embeddings
- Open Source Beispiele zum testen
- Machine Learning Methoden
 - Regressions- und Klassifikationsverfahren
- Werk steht zur freien Verfügung: <https://smaltar.com/>



4. Automatisierung via Texterkennungs-Algorithmus

Unabhängige Variablen

Geschäftsfall: 8000641462, Rückweisung - Notizen

Zurück | Neu | Notizblock importieren

Textart: Rückweisungsgrund

Text

1) Wir haben bis heute keine Unfallmeldung erhalten. Bitte stellen Sie die Rechnung auf dem Rückerstattungsweg des Patienten zu.
006223Wir haben bis heute keine Unfallmeldung erhalten. Bitte stellen Sie die Rechnung auf dem Rückerstattungsweg des Patienten zu.
Kontaktperson: Nachname: Zdrle, Vorname: , Telefon: +41 52 266 77 72, Email: [REDACTED]
Firma: Telefon: , Email:

Falldaten zur Beschwerde

Patient: [REDACTED]
Fallart: ambulanter Fall
Fall: [REDACTED]
Falltyp: [REDACTED]
Fachliche OE: 00007500
Beh. OE: 00001944
Rechnungsnummer: [REDACTED]
Nettowert:
DRG-Code (alt):
DRG-Code (neu):
Bewertungsrelation (alt):
Bewertungsrelation (neu):

ML-Script

Abhängige Variablen

Geschäftsfall: 8000641462, Unfallmeldung fehlt

Sichern | Abbrechen | Bearbeiten | Folgevorgang anlegen

Details

Allgemeine Daten

* Beschreibung: Unfallmeldung fehlt
Freitext:
Patient: [REDACTED]
Beschwerdeführer: Sanitas
Ansprechperson:
Bearbeitende Person:
Bearbeitendes Team: Externer Auftrag und Patientenanfrage
Verantwortliche Person: Hanspeter Peterhans

Verarbeitungsdaten

Priorität: mittel
Status: In Arbeit
Erledigungscode:
Kategorie 1: Rechnungsbeschwerte
Kategorie 2: Kostenübernahme
Kategorie 3: Unfallmeldung fehlt

5. Scripts

Bereitstellung Testdaten

- Bereinigung alter Testdaten für neue kohärente Kategorisierungslogik
- Resultat: Cirka 100'000 Testdaten

Bereinigung Textdaten

- Entfernung unnötiger Strings via RegEx
- Erstellung USZ Stopword Liste
- Empfehlung: stringr

Trainierung ML-Modelle

- Trainierung mehrerer Modelle und Hyperparameter Tuning
- Multinominale logistische Regression
- Random Forest
- Support Vector Machine
- Empfehlung: tidymodels

Kombination der Modelle

- Erreichung von 84% Genauigkeit der Kombination der Modelle
- Qualitätsanalyse via Heatmaps
- Prädiktion und Anwendung auf neue elektronische Rückweisungen

6. Ausblick

CRM-Tool

- Weitere Automatisierungsschritte wie die automatisierte Geschäftsfalleröffnung bei eingehenden E-Mails und eingescannten Briefen via OCR, Einbezug des Triage-Algorithmus
- Prozessautomatisierung via RPA (Robotic Process Automation)

ML-Server für R und Python

- Errichtung eines R- und Python Machine Learning-Servers in SAP 4/HANA sowie Errichtung einer API zum CRM-Tool
- Weiterentwicklung der Modelle mit Deep Learning
 - Neural Networks, Long Short-Term Memory und Convolutional Neural Networks

DPoP

- Data Platforms of Platforms, USZ-weites Projekt zur Errichtung einer Datenplattform mit einer Data Science und ML-Workbench

7. Fragen



R@USZ

Umsetzung in R

Gregori Schmid, Data Scientist

Agenda

Beispiel in R

1. Workflow in R mit *TidyModels* und einem Beispielmodel
2. Konkretes Beispiel mit Predictions am USZ
3. Exkurs: Democratic Stacking Machine Learning Ensemble (DS-MLE)

1. Workflow in R mit *TidyModels* und einem Beispielmudel



Workflow in R mit *TidyModels*



Arbeitsablauf beim Kochen für die Woche

1. Lebensmittel einkaufen & nach Hause bringen
2. Küche putzen
3. Lebensmittel bereitstellen
4. Rezeptbuch herbeiziehen
5. Haupt- und Beilagen einplanen
6. Menü im Rezeptbuch aufschlagen
7. Zubereitung gemäss Rezept
8. Abschmecken
9. Essen in Tupperware verpacken
10. Essen

Workflow in TidyModels

1. Datenbeschaffung & Datenimport
2. Datenaufbereitung (Nicht vorhandene, fehlerhafte...)
3. Split
4. Recipe
5. Cross-Validation
6. Model (z.B. Support Vector Machine – SVM)
7. Workflow
8. Quality Analysis
9. Finalize & Save Workflow
10. Predict

Anwendungsbeispiel




2. Konkretes Beispiel mit Predictions am USZ

Konkretes Beispiel mit Predictions

Genauigkeit: 84.1727629520696 %

Gezeigt werden nur Konstellationen mit ≥ 40 Messungen

Zeitraum: 2019 - 2023



Democratic Stacking Machine Learning Ensemble (DS-MLE)

Wir haben mehrere Modelle

Truth	Model 1	Model 2	Model 3
D	D	D	D
D	D	A	D
A	A	A	D
C	A	B	C
B	C	C	B
A	B	C	C
B	B	B	A
B	B	B	B
C	A	C	C
A	A	A	D

Democratic Stacking Machine Learning Ensemble (DS-MLE)

Wir haben mehrere Modelle nach Accuracy

Truth	Model 1: 60%	Model 2: 60%	Model 3: 70%
T	T	T	T
T	T	F	T
T	T	T	T
T	F	F	T
T	F	F	T
T	F	F	F
T	T	T	F
T	T	T	T
T	T	T	T
T	F	T	F

Democratic Stacking Machine Learning Ensemble (DS-MLE)

Wir haben mehrere Modelle: Abstimmung

Truth	Model 1	Model 2	Model 3	DS-MLE
D	D	D	D	
D	D	A	D	
A	A	A	D	
C	A	B	C	
B	C	C	B	
A	B	C	C	
B	B	B	A	
B	B	B	B	
C	A	C	C	
A	A	A	D	

Democratic Stacking Machine Learning Ensemble (DS-MLE)

Wir haben mehrere Modelle: Abstimmung

Truth	Model 1	Model 2	Model 3	DS-MLE
D	D	D	D	D
D	D	A	D	D
A	A	A	D	A
C	A	B	C	?
B	C	C	B	C
A	B	C	C	C
B	B	B	A	B
B	B	B	B	B
C	A	C	C	C
A	A	A	D	A

Democratic Stacking Machine Learning Ensemble (DS-MLE)

Wir haben mehrere Modelle: Abstimmung + Best Model (Model 3)

Truth	Model 1	Model 2	Model 3	DS-MLE
D	D	D	D	D
D	D	A	D	D
A	A	A	D	A
C	A	B	C	C
B	C	C	B	C
A	B	C	C	C
B	B	B	A	B
B	B	B	B	B
C	A	C	C	C
A	A	A	D	A

Democratic Stacking Machine Learning Ensemble (DS-MLE)

Wir haben mehrere Modelle: Abstimmungsergebnisevaluation

Truth	Model 1 60%	Model 2 60%	Model 3 70%	DS-MLE 80%
T	T	T	T	T
T	T	F	T	T
T	T	T	T	T
T	F	F	T	T
T	F	F	T	F
T	F	F	F	F
T	T	T	F	T
T	T	T	T	T
T	T	T	T	T
T	F	T	F	T

Democratic Stacking Machine Learning Ensemble (DS-MLE)

Wir haben mehrere Modelle: Praxisbeispiel

Model 1: 79.91176%

Model 2: 83.99105%

Model 3: 84.00978%

DS-MLE: 84.17276%

Gewinn: 0.16298%


In Absoluten Zahlen:

163 Fälle zusätzlich richtig vorhergesagt


ACHTUNG:

- Funktioniert nur ab einem gewissen Grad der Fehlersymmetrie der Modelle.
- Liegt eine zu starke Asymmetrie der Fehlerverteilungen zwischen den Modellen vor, dann wird die im DS-MLE entstandene Fehlermenge grösser sein, als die Fehlermenge des besten Modells für sich alleine.
- Je symmetrischer die Fehlerverteilungen und je ähnlicher die Vorhersagegenauigkeiten der einzelnen Modelle, um so grösser ist der positive Effekt durch DS-MLE.

MLEs funktionieren auch mit anderen ML-Typen, sind vom Aufbau her aber immer gleich



Noch Fragen?



Snelliussches Brechungsgesetz

$$\frac{\sin \delta_1}{\sin \delta_2} = \frac{n_2}{n_1} \longrightarrow \sin \delta_1 \cdot n_1 = \sin \delta_2 \cdot n_2$$

Weiterführende Literatur

- R Tutorial (basics): <https://www.w3schools.com/r/default.asp>
- Machine Learning (basics): https://w3schoolsua.github.io/ai/index_en.html#gsc.tab=0
- **Tidy Modeling with R:** <https://www.tmwr.org/>
- **Supervised Machine Learning for Text Analysis in R:** <https://smltar.com/>
- Introductory predictive analytics and machine learning in education and healthcare:
<https://bookdown.org/anshul302/paml/>

Vielen Dank für eure Aufmerksamkeit!

